

Задание №1.

Вариант 5

Выполнил студент гр. НТм(до)з-25-1

Якимов Сергей Анатольевич

Смоделировать нейронную сеть для поиска точки минимума для функции с одной (задание А) и двумя переменными (задание Б). Поиск осуществить с использованием методов градиентного спуска, покоординатного спуска и адаптивным методом градиентного спуска.

Таблица 1.3

Варианты заданий

Вариант	Задание А	Начальная точка	Задание Б	Начальная точка
5	$x^3 - 3\sin x$	[0;1]	$2x_1^2 + 2x_2^2 + 2x_1x_2 - 14x_1 - 12x_2 + 29$	[-1;4]

Дополнительное задание

Определить оптимальные параметры веса w_1 , w_2 и смещение b для нейронной сети (рисунок 1.4), если имеется тренировочная выборка (таблица 1.4).

Таблица 1.4

Тренировочная выборка

Объект	Вес, кг	Рост, см	Пол человека
A_1	84	180	1
A_2	62	172	0
A_3	57	165	0
A_4	свой вес	свой рост	свой пол

Отчёт

1-й этап: подготовка данных и формализация эксперимента

На первом этапе необходимо определить размерность задачи, диапазоны величин и способ представления результатов. В текущем случае «данными» являются скалярная или векторная переменная состояния (x для задания А и (x_1, x_2) для задания Б), а также значение целевой функции f и её градиент на каждой итерации.

Для задания А пространство поиска одномерное: на каждом шаге алгоритм хранит текущее приближение x_k и последовательность значений $f(x_k)$ для последующего построения графика сходимости.

Для задания Б пространство двумерное: хранятся пары $(x_1, x_2)_k$ и значения $f(x_1, x_2)_k$. Норма градиента $|\nabla f|$ используется как индикатор близости к стационарной точке; при $|\nabla f| < \varepsilon$ итерации прекращаются.

Дополнительное задание использует табличную выборку объектов $A_1 \dots A_3$ с признаками «масса тела (кг)» и «рост (см)» и бинарной меткой пола (1 — мужской, 0 — женский).

2-й этап: выбор методов оптимизации («создание модели»)

Во втором этапе, по смыслу соответствующем блоку «создание сети» в образце, задаётся набор используемых процедур минимизации. В работе применяются три метода:

1) Градиентный спуск. На каждой итерации вычисляется градиент ∇f в текущей точке и выполняется шаг $x_{k+1} = x_k - \eta \nabla f(x_k)$. В реализации используется дробление шага (backtracking): если очередной шаг не уменьшает f , шаг η уменьшается вдвое до достижения убывания функции либо до исчерпания нижней границы шага.

2) Покоординатный спуск. Вектор обновляется покомпонентно: для каждой координаты выполняется одномерный спуск вдоль соответствующей частной производной при фиксированных остальных

переменных. Такой подход часто применяют, когда полный градиентный шаг неудобен или когда структура задачи «почти разделяема» по координатам.

3) Адаптивный градиентный спуск (вариант Adagrad). Накопительные суммы квадратов компонент градиента G_i используются для индивидуальной подстройки эффективного шага по каждой координате: $\eta_i = \eta / (\sqrt{G_i} + \epsilon)$. Это снижает чувствительность к выбору глобальной скорости обучения по сравнению с классическим градиентным спуском с фиксированным η .

Реализация всех трёх методов содержится в модуле исходного кода; ключевые фрагменты именуются `gradient_descent`, `coordinate_descent`, `adaptive_gradient_descent`.

```
# Пример вызова (см. полный код в файле исходников):
task_a_results = [
    gradient_descent(f_a, grad_a, x0_a, lr=0.05),
    coordinate_descent(f_a, grad_a, x0_a, lr=0.1),
    adaptive_gradient_descent(f_a, grad_a, x0_a, lr=0.8),
]
```

3-й этап: параметры итерационного процесса («обучение»)

Третий этап соответствует настройке параметров обучения в примере с MATLAB (`performFcn`, `goal`, `epochs`). В текущей постановке роль функционала ошибки выполняет сама целевая функция f : на каждой итерации отслеживается убывание $f(x)$ или $f(x_1, x_2)$.

Основные гиперпараметры: начальные скорости обучения η (различаются для методов и для задач А и Б — см. код), допуск по норме градиента для останова, максимальное число итераций, нижняя граница шага при дроблении. При достижении $|\nabla f| < 10^{-7}$ итерации завершаются; при невозможности уменьшить f на шаге процесс также останавливается.

Для дополнительного задания используется правило обучения персептрона Розенблатта с нормировкой признаков по столбцам (вычитание среднего, деление на стандартное отклонение) для устойчивости сходимости при разном масштабе «кг» и «см».

4-й этап: результаты и анализ сходимости («тестирование»)

На четвёртом этапе, аналогично разделу тестирования в образце, представляются численные результаты и графическая диагностика. Ниже приведены таблицы найденных минимумов для заданий А и Б по каждому методу (значения получены программно при формировании отчёта).

Таблица 1. Результаты минимизации (задание А)

Метод	x^*	$f(x^*)$	Итераций (шагов)
Градиентный спуск	0.82413230	-1.64213041	43
Покоординатный спуск	0.82413228	-1.64213041	15
Адаптивный градиентный спуск	0.82413232	-1.64213041	126

Графики зависимости значения функции от номера итерации иллюстрируют скорость снижения f и позволяют сравнить методы визуально (ср. с графиком ошибки по эпохам в примере с train).




Рисунок 1 — Сходимость методов для задания А ($f(x) = x^3 - 3 \sin x$).




Рисунок 2 — Сходимость методов для задания Б (квадратичная функция двух переменных).

Интерпретация. Для задания Б все три метода должны приближаться к аналитическому минимуму $(8/3; 5/3)$ с $f_{\min} = 1/3$; расхождения в числе итераций отражают разную эффективность на данной квадратичной поверхности. Для задания А сравнение методов показывает, насколько быстро каждый из них уменьшает f при выбранных η и стратегии шага.

```

~/w/M/NEURO_MATH/neuro_math_Yakimov_var5  P develop !1 ?1 python -m task_1.practice01
=====
Практическая работа №1, вариант 5 – результаты численного эксперимента
=====

[1/3] Задание А:  $f(x) = x^3 - 3 \cdot \sin(x)$ 
Старт:  $x_0 = 0$  (допустимый интервал по заданию:  $[0; 1]$ )
Сравнение трёх методов минимизации (см. также график в PNG).

Задание А – итоги по методам:
• Градиентный спуск
   $x^* = 0.8241322999$ 
   $f(x^*) = -1.6421304129$ 
   $\|f'\|$  в конце  $\approx 8.86e-08$  | шагов в истории: 43
• Покоординатный спуск
   $x^* = 0.8241322750$ 
   $f(x^*) = -1.6421304129$ 
   $\|f'\|$  в конце  $\approx 2.66e-07$  | шагов в истории: 15
• Адаптивный градиентный спуск
   $x^* = 0.8241323249$ 
   $f(x^*) = -1.6421304129$ 
   $\|f'\|$  в конце  $\approx 8.98e-08$  | шагов в истории: 126

[2/3] Задание Б: квадратичная  $f(x_1, x_2)$  из варианта 5
Старт:  $(x_1^{(0)}, x_2^{(0)}) = (-1, 4)$ 
Эталон (аналитика,  $\nabla f=0$ ):  $x^* \approx (8/3, 5/3)$ ,  $f_{\min} = 1/3 \approx 0.333333...$ 

Задание Б – итоги по методам:
• Градиентный спуск
   $(x_1^*, x_2^*) = (2.6666665631, 1.6666667702)$ 
   $f(x^*) = 0.3333333333$ 
   $\|\nabla f\|$  в конце  $\approx 2.93e-07$  | шагов в истории: 77
• Покоординатный спуск
   $(x_1^*, x_2^*) = (2.6666666033, 1.6666667104)$ 
   $f(x^*) = 0.3333333333$ 
   $\|\nabla f\|$  в конце  $\approx 1.73e-07$  | шагов в истории: 48
• Адаптивный градиентный спуск
   $(x_1^*, x_2^*) = (2.6666666354, 1.6666666839)$ 
   $f(x^*) = 0.3333333333$ 
   $\|\nabla f\|$  в конце  $\approx 9.09e-08$  | шагов в истории: 137

[3/3] Дополнительное задание: персептрон (вес, рост)  $\rightarrow$  пол
Веса ниже – в пространстве нормированных признаков (z-score по столбцам).

Дополнительное задание:
•  $w_1 = 0.3751574787$ ,  $w_2 = 0.2610855803$ ,  $h = 0.0000000000$ 
• Предсказания на обучающей выборке (0/1): [1, 0, 0]

```

Рисунок 3 — скриншот консоли

5-й этап: дополнительное задание и выводы («моделирование»)

На заключительном этапе выполняется дополнительное задание: подбор весов w_1 , w_2 и смещения h для линейного порога $\sigma(w_1 \cdot x_1 + w_2 \cdot x_2 + h)$, где x_1 — масса, x_2 — рост. После нормировки признаков получены следующие параметры (в пространстве нормированных признаков):

$w_1 = 0.375157$, $w_2 = 0.261086$, $h = 0.000000$. Метки на обучающей выборке после обучения: $[1, 0, 0]$.

Проверка: для объектов из таблицы задания классы должны совпадать с эталоном; при добавлении строки A_4 необходимо заново вызвать процедуру обучения и занести в отчёт обновлённые w_1 , w_2 , h и матрицу нормировки (среднее и σ по столбцам).

Выводы по работе: реализованы три метода безусловной оптимизации; на квадратичной функции (задание Б) результаты согласуются с аналитическим минимумом; графики сходимости демонстрируют устойчивое убывание целевой функции; персептрон на учебной выборке позволяет восстановить разделяющую линию в пространстве признаков.

Ссылка на исходный код

Полный программный код решения практической части расположен в файле «neuro_math_Yakimov_var5/task_1/practice01.py»