

Выполнил студент гр. НТм(до)з-25-1

Якимов Сергей Анатольевич

Зачетная книжка: 25-00-00295

Задание №2

Вариант 5

Задание 1

Смоделировать НС для тренировочной выборки (варианты заданий - таблицы 2.7, 2.8). Получить функциональную зависимость для тренировочной выборке НС, построить ее график. Проверить результат с использованием тестовой выборки.

Таблица 2.7

Тренировочная выборка		
№	x	Y
1	-1	1
2	0	0
3	1	1
4	2	4
5	-1	0
6	1	1
7	0	1
8	1	0
9	2	3
10	2	-2

Таблица 2.8

Варианты заданий	
Номер варианта	Задание 1 Номера комбинаций логических переменных
5	7,8,9,10

Задание 2

Подготовить данные по теме (варианты заданий - таблицы 2.9). Смоделировать НС и получить функциональную зависимость для тренировочной выборке НС, построить ее график. Проверить результат с использованием тестовой выборки.

Таблица 2.9

Тренировочная выборка		
<i>Вариант</i>	<i>Задание</i>	<i>Дата сет</i>
5	<i>Прогнозирование цен акций</i> Постройте модель нейронной сети для предсказания цен акций. Используйте временные ряды и финансовые индикаторы, такие как объемы торгов, индексы волатильности и макроэкономические показатели	

Отчёт

Метрики качества регрессии

Для оценки близости предсказаний $\hat{y}$ к эталонным значениям y на обучающей и тестовой выборках используются стандартные показатели, реализованные в библиотеке `scikit-learn`.

Среднеквадратичная ошибка (MSE): $MSE = (1/n) \sum_i (y_i - \hat{y}_i)^2$. Чем меньше MSE, тем ближе прогноз к целевой переменной в квадратичном смысле; при сравнении моделей удобно также смотреть на $RMSE = \sqrt{MSE}$ в тех же единицах, что и Y .

Средняя абсолютная ошибка (MAE): $MAE = (1/n) \sum_i |y_i - \hat{y}_i|$. Интерпретируется как типичное отклонение прогноза по модулю, менее чувствительна к редким большим ошибкам, чем MSE.

Коэффициент детерминации R^2 : чем ближе к 1, тем большая доля дисперсии целевой переменной объясняется моделью; отрицательные значения R^2 означают, что модель в среднем хуже наивного предсказания константой (средним по выборке). На малых и противоречивых выборках R^2 может быть нестабильным, поэтому его следует сопоставлять с MSE/MAE и содержательной интерпретацией данных.

1-й этап: подготовка данных

Исходная таблица 2.7 задаёт дискретные наблюдения пары скалярных величин: аргумент X и отклик Y . Перед обучением нейронной сети важно явно зафиксировать, какие строки относятся к обучению, а какие — к контролю обобщения. Перемешивание строк в задании 1 не применяется: разбиение детерминировано номером варианта.

Таблица А. Тренировочная выборка (строки 7–10 табл. 2.7, вар. 5)

№	X	Y
1	0	1
2	1	0
3	2	3
4	2	-2

Таблица Б. Тестовая выборка (остальные строки табл. 2.7)

№	X	Y
1	-1	1
2	0	0
3	1	1
4	2	4
5	-1	0
6	1	1

Особенность данных: в тренировочной выборке присутствуют две записи с одинаковым значением $x = 2$ и разными откликами $Y = 3$ и $Y = -2$. В классическом понятии функции $y = f(x)$ одному аргументу не может соответствовать два различных значения отклика; минимизация среднеквадратичной ошибки на таких точках приводит к компромиссному значению предсказания в окрестности $x = 2$. Это необходимо учитывать при анализе метрик на тесте: например, точка (2; 4) из тестовой части таблицы может оказаться далеко от кривой, построенной нейросетью, не из-за «плохого» обучения, а из-за внутренней неоднозначности обучающей подвыборки.

Для задания 2 синтетический ряд моделирует динамику цены закрытия и сопутствующего объёма торгов. Из уровней цен вычисляются логарифмические доходности; по скользящему окну оценивается локальная волатильность (стандартное отклонение доходностей) как упрощённый аналог индикатора волатильности. В вектор признаков на момент времени t дополнительно включается текущий уровень цены: без него модель в масштабе абсолютных цен на отложенном тесте часто теряет устойчивость, так как лаги доходностей сами по себе не несут информации о текущем уровне ряда.

Целевая переменная — цена на следующий торговый день (одношаговый горизонт прогноза). Длина ряда и доля обучающих наблюдений задаются в программе (по умолчанию длина ряда 600 точек, доля обучения около 82% от числа сформированных пар признак–ответ). Разбиение строго хронологическое: тестовый участок соответствует более

поздним датам; перемешивание точек временного ряда недопустимо, иначе оценка качества завышается за счёт утечки «будущего» в признаки.

2-й этап: выбор модели нейронной сети

В обоих заданиях используется многослойный перцептрон для регрессии — класс `sklearn.neural_network.MLPRegressor`. Это полносвязная сеть прямого распространения: каждый нейрон скрытого слоя получает взвешенную сумму входов, к которой применяется нелинейная функция активации (в работе — гиперболический тангенс $\tanh$), после чего сигнал передаётся на следующий слой или на выходной нейрон с линейной идентичностью (регрессия вещественного отклика).

В качестве численного решателя для подбора весов выбран L-BFGS (ограниченно-памятный метод Бroyдена–Флетчера–Гольдфарба–Шанно). Для небольших табличных задач и умеренной размерности сети этот метод часто сходится быстрее и стабильнее стохастического градиентного спуска без тонкой настройки скорости обучения. К входным признакам применяется `StandardScaler` (нулевое среднее, единичная дисперсия по каждому столбцу на обучающей выборке); для задания 2 аналогично масштабируется целевая переменная на этапе обучения, после чего предсказания переводятся обратно в исходный масштаб цен.

Регуляризация L2 задаётся параметром `alpha`: штраф за большие веса снижает риск переобучения на шумных данных. Для задания 1 сеть небольшая (два скрытых слоя по 12 нейронов), $\alpha = 10^{-4}$. Для задания 2 — слои 32 и 16 нейронов, $\alpha = 5 \cdot 10^{-3}$, что соответствует чуть более сильному сглаживанию на фоне большего числа наблюдений.

Запуск рабочей программы из каталога пакета (пример для консоли и скриншота в отчёт):

```
cd neuro_math_Yakimov_var5
python -m task_2.practice02
```

3-й этап: обучение нейронной сети

Обучение сводится к минимизации функционала среднеквадратичной ошибки между предсказаниями сети и эталонными значениями Y (задание 1) или между предсказанной и фактической ценой (задание 2). Итерации L-BFGS продолжаются до выполнения условия сходимости по tol либо до исчерпания max_iter .

Практическая ремарка: если библиотека выводит предупреждение о неполной сходимости L-BFGS за отведённое число итераций, имеет смысл проверить масштаб целевой переменной (стандартизация y), увеличить max_iter или слегка ослабить tol . В актуальной версии программы для задания 2 цель стандартизована, что обычно устраняет подобные предупреждения.

4-й этап: результаты на обучении и тесте, графики

Ниже приведены сводные таблицы метрик. Значения получены при последнем прогоне программы, формирующей настоящий отчёт; при изменении $seed$ генератора синтетического ряда или гиперпараметров сети цифры могут незначительно отличаться.

Таблица В. Задание 1 — метрики регрессии

Выборка	MSE	MAE	R^2
Обучение	3.125000	1.250202	0.038462
Тест	3.232824	1.533359	-0.790487

Таблица Г. Задание 2 — метрики регрессии

Выборка	MSE	MAE	R^2
Обучение	0.001451	0.024042	0.999981
Тест	20.886885	3.496865	0.363120

Для задания 1 на обучении: $RMSE \approx 1.7678$, на тесте $RMSE \approx 1.7980$ (в тех же единицах, что и Y). Для задания 2 на обучении $RMSE \approx 0.0381$, на тесте $RMSE \approx 4.5702$ (единицы — условные единицы цены синтетического ряда).

Графическая часть задания 1 (рисунок 1) показывает обучающие точки, тестовые точки и непрерывную кривую, полученную сетью на

плотной сетке по оси X. Такой график аналогичен построению «функциональной зависимости» после обучения. Графическая часть задания 2 (рисунок 2) содержит полный ряд цен с вертикальной линией разделения выборок и отдельный фрагмент сравнения факта и прогноза на тестовом отрезке.




Рисунок 1 — Задание 1: точки обучения и теста, кривая аппроксимации нейронной сети.




Рисунок 2 — Задание 2: ряд цен с границей train/test и сравнение факта с прогнозом на тесте.

```
~/M/NEURO_MATH/neuro_math_Yakimov_var5 P develop !3 ?? python -m task_2.practice02
Практическая работа №2, вариант 5

[1/3] Задание 1 — НС по табл. 2.7 (обучение: строки 7, 8, 9, 10)
Тренировочные точки (x, Y):
[[ 0.  1.]
 [ 1.  0.]
 [ 2.  3.]
 [ 2. -2.]]
Тестовые точки — остальные строки таблицы:
[[-1.  1.]
 [ 0.  0.]
 [ 1.  1.]
 [ 2.  4.]
 [-1.  0.]
 [ 1.  1.]]
Метрики на обучении: {'mse': 3.125000093809639, 'mae': 1.2502019540574323, 'r2': 0.038461509597034094}
Метрики на тесте: {'mse': 3.232823773334483, 'mae': 1.5333590269387416, 'r2': -0.7904870129237136}
Примечание: при x=2 в обучении два разных Y — НС аппроксимирует в смысле MSE.

[2/3] Задание 2 — прогноз цен акций (синтетический OHLCV-подобный ряд)
Длина ряда close: 600, образцов признаков: 596, train/test по точкам = 82% / 18%
Метрики на обучении: {'mse': 0.001451224688234173, 'mae': 0.024042018954488365, 'r2': 0.9999805412586655}
Метрики на тесте: {'mse': 20.886884724408542, 'mae': 3.496864757951132, 'r2': 0.3631200844099526}

[3/3] Файлы результатов:
/home/garjelin/work/MAGA/NEURO_MATH/neuro_math_Yakimov_var5/outputs/practice02
• task1_plot: /home/garjelin/work/MAGA/NEURO_MATH/neuro_math_Yakimov_var5/outputs/practice02/practice02_task1_fit.png
• task2_plot: /home/garjelin/work/MAGA/NEURO_MATH/neuro_math_Yakimov_var5/outputs/practice02/practice02_task2_forecast.png
```

Рисунок 3 — скриншот консоли

5-й этап: выводы и направления развития

По заданию 1 продемонстрирована способность многослойного перцептрона в режиме регрессии строить гладкую аппроксимацию по малому числу точек. Качество на тесте ограничено не только архитектурой, но и самой постановкой: противоречивые пары при одинаковом x не позволяют интерпретировать результат как восстановление единственной истинной функции. Для учебных целей это полезный пример обсуждения разницы между «обучением на таблице» и «идентификацией функции».

По заданию 2 реализован типичный для прогноза акций конвейер: формирование признаков из истории цен и объёма, хронологическое разбиение, обучение нейросети и визуальная проверка на отложенном участке. Переход на реальные данные потребует учёта пропусков, сплитов и корпоративных событий, выбора горизонта прогноза, возможного ансамбля моделей и отдельной валидации на нескольких временных окнах.

Возможные улучшения: для задания 1 — явное введение стохастической постановки или классификации при дискретном x ; для задания 2 — рекуррентные архитектуры (LSTM, GRU), более богатый набор индикаторов (скользящие средние, MACD), кросс-валидация по

времени (time series split), подбор гиперпараметров по сетке или байесовской оптимизации.

Ссылка на исходный код

Исходный код решения практической части расположен в файле «neuro_math_Yakimov_var5/task_2/practice02.py».