

Выполнил студент гр. НТм(до)з-25-1

Якимов Сергей Анатольевич

Зачетная книжка: 25-00-00295

Задание №5

Вариант 5

Задание 1

Смоделировать НС, которая будет предсказывать ремонт двигателя по результатам двух признаков: температура подшипника и наличие вибрации. Тренировочная и тестовая выборка состоит из следующих наблюдений (таблица 5.16).

Таблица 5.16

Тренировочная и тестовая выборка

№	Температура подшипника, град	Вибрация, мм/с	Требуется ремонт
1	125	1,8	да
2	100	1,0	нет
3	70	0,9	нет
4	80	0,76	нет
5	105	1,1	да
6	85	1,9	да
7	60	0,6	нет
8	65	0,5	нет
9	90	1,5	да
10	86	1,7	да

Задание 2

Смоделировать НС, которая будет предсказывать параметры задачи классификации. Тренировочную выборку сформировать самостоятельно в зависимости от темы и варианта (таблица 5.21).

Таблица 5.21

Формулировка задачи классификации

Вариант	Тема	Задача классификации	Параметры
5	Предсказание метеорологических условий	Предсказание температуры и погодных условий на основе исторических метеоданных	Температура, влажность и другие метеорологические параметры, зависящие от
			предыдущих значений

Отчёт

Задание 1.

1) Постановка задачи.

Требуется смоделировать нейронную сеть, которая предсказывает необходимость ремонта двигателя по двум входным признакам: температуре подшипника (°C) и уровню вибрации (мм/с). Выход интерпретируется как бинарная классификация: «да» — требуется ремонт; «нет» — не требуется.

2) Исходные данные.

Использованы все 10 наблюдений из таблицы 5.16 методички. В коде классы закодированы численно: «нет» → 0, «да» → 1. Для контроля обобщения выполнено случайное стратифицированное разбиение на обучение и тест с долей теста 20% при фиксированном генераторе случайных чисел, чтобы результат был воспроизводимым.

Оказалось в обучении (номера строк по методичке): (1, 2, 3, 4, 5, 6, 8, 9). Оказалось в тесте: (7, 10).

3) Архитектура модели и предобработка.

Применён многослойный персептрон `MLPClassifier` из `scikit-learn` с двумя скрытыми слоями (24 и 12 нейронов), функцией активации ReLU и решателем Adam. Признаки стандартизованы через `StandardScaler` по обучающей части, после чего те же параметры масштабирования применяются к тесту.

4) Результаты.

Таблица 1. Метрики качества классификации (задание 1)

Выборка	Accuracy	Precision	Recall	F1
Обучение	1.0000	1.0000	1.0000	1.0000
Тест	1.0000	1.0000	1.0000	1.0000

Дополнительно сформирована матрица ошибок на тестовой подвыборке (см. рисунок ниже). Также приведён текстовый

`classification\_report`, который автоматически выводится программой при запуске скрипта.

5) Иллюстрации.




Рисунок 1 — Задание 1: карта вероятности класса «да» и разделяющая линия уровня 0.5.




Рисунок 2 — Задание 1: матрица ошибок на тесте (строки — факт, столбцы — прогноз).

Задание 2.

1) Формулировка задачи.

По таблице 5.21 для варианта 5 темой является предсказание метеорологических условий на основе исторических метеопараметров. В данной работе реализован учебный синтетический временной ряд, имитирующий последовательность наблюдений по дням: температура воздуха, относительная влажность и атмосферное давление.

Целевая переменная — бинарный признак наличия осадков на следующий день относительно текущего наблюдения (переход $t \rightarrow t+1$). Таким образом, на вход сети подаются значения метеополей на шаге t , а обучение выполняется как классификация события «осадки завтра».

2) Формирование выборки.

Объём последовательности после формирования признаков и метки: 519 наблюдений. Разбиение на обучение и тест выполняется хронологически (без перемешивания вперёд по времени), что соответствует реалистичной постановке прогноза по прошлому. Если при выбранной доле обучения на тестовом отрезке отсутствует один из классов, программа автоматически подбирает близкую долю обучения так, чтобы и на обучении, и на тесте присутствовали оба класса.

Итоговые размеры: обучение — 405 точек, тест — 114 точек; эффективная доля обучения составляет примерно 78.0%. Вектор признаков на шаге t : $T(t)$, $RH(t)$, $P(t)$.

3) Модель.

Использован `MLPClassifier` с двумя скрытыми слоями (36 и 18 нейронов), активацией $\tanh$ и решателем Adam. Признаки стандартизуются по обучающему отрезку времени. Выбор архитектуры и числа итераций определяется небольшим экспериментом по сходимости на синтетических данных и может быть уточнён при переходе на реальные архивы метеонаблюдений.

4) Результаты.

Таблица 2. Метрики качества классификации (задание 2)

Выборка	Accuracy	Precision	Recall	F1
Обучение	0.6667	0.6467	0.6296	0.6381
Тест	0.6053	0.6582	0.7429	0.6980

На реальных данных качество обычно ниже из-за шума, неучтённых факторов и нестационарности климата; здесь синтетическая модель нужна для демонстрации полного конвейера: генерация ряда $\rightarrow$ признаки $\rightarrow$ обучение $\rightarrow$ тест.

5) Иллюстрации.



Рисунок 4 — Задание 2: фрагмент ряда влажности и соответствующая бинарная метка осадков ($t \rightarrow t+1$).




Рисунок 5 — Задание 2: матрица ошибок на тестовом временном участке.

Вывод

Выполнены оба задания практики №5 для варианта 5: построена нейросеть для табличной классификации признаков диагностики двигателя и отдельно реализован учебный конвейер классификации метеосценария по синтетическому ряду. Получены количественные метрики на отложенном контроле и графические иллюстрации для включения в отчёт.

Ссылка на исходный код

Рабочий скрипт задания:

``neuro_math_Yakimov_var5/task_5/practice05.py``.

```
~/M/NEURO_MATH/neuro_math_Yakimov_var5 P develop 13 75 python -m task_5.practice05
Практическая работа №5, вариант 5

[1/2] Задание 1 – таблица 5.16 (ремонт двигателя: да/нет)
Строки таблицы в обучении (№ по методичке): (1, 2, 3, 4, 5, 6, 8, 9)
Строки таблицы в тесте: (7, 10)
Метрики на обучении: {'accuracy': 1.0, 'precision': 1.0, 'recall': 1.0, 'f1': 1.0}
Метрики на тесте: {'accuracy': 1.0, 'precision': 1.0, 'recall': 1.0, 'f1': 1.0}
Матрица ошибок (test), строки=факт, столбцы=прогноз [нет, да]:
[[1 0]
 [0 1]]
classification_report (test):
      precision    recall  f1-score   support

   нет         1.00      1.00       1.00         1
    да         1.00      1.00       1.00         1

   accuracy         1.00      1.00       1.00         2
  macro avg         1.00      1.00       1.00         2
weighted avg         1.00      1.00       1.00         2

[2/2] Задание 2 – таблица 5.21, тема «метеоданные» (осадки t-t+1)
Supervised-выборка: 519 точек; train/test по времени: 405 / 114 (эффективная доля обучения = 78%)
Признаки на шаг t: ['T(t)', 'RH(t)', 'P(t)'] – цель: осадки на день t+1
Метрики на обучении: {'accuracy': 0.6666666666666666, 'precision': 0.6467391304347826, 'recall': 0.6296296296296297, 'f1': 0.6380697050938338}
Метрики на тесте: {'accuracy': 0.6052631578947368, 'precision': 0.6582278481012658, 'recall': 0.7428571428571429, 'f1': 0.697986577181208}
Матрица ошибок (test), строки=факт, столбцы=прогноз:
[[17 27]
 [18 52]]
classification_report (test):
      precision    recall  f1-score   support

нет осадков      0.49      0.39      0.43        44
есть осадки      0.66      0.74      0.70        70

   accuracy         0.57      0.56      0.56       114
  macro avg         0.57      0.56      0.56       114
weighted avg         0.59      0.61      0.59       114

[файлы]
/home/garjelin/work/MAGA/NEURO_MATH/neuro_math_Yakimov_var5/outputs/practice05
• task1_boundary: outputs/practice05/practice05_task1_boundary.png
• task1_confusion_test: outputs/practice05/practice05_task1_confusion_test.png
• task2_confusion_test: outputs/practice05/practice05_task2_confusion_test.png
```

Рисунок 6 — Скрин консоли