

Выполнил студент гр. НТм(до)з-25-1

Якимов Сергей Анатольевич

Зачетная книжка: 25-00-00295

Задание №8

Вариант 5

Задание 1

В качестве текста выберем поэтические строки (таблица 8.9).
Подготовить тренировочную выборку всеми возможными способами.
Постройте модель нейронной сети, оцените ее качество.

Таблица 8.9

Задание по вариантам

Вариант	Текст
5	За горизонтом мечты, Мы будем их трактовать в тени, Где поэзия сливается в нейронный свет.

Отчёт

Часть 1. Нейросеть: предсказание следующего символа

Цель и метрики

Целевая переменная — следующий символ; признак — one-hot по контексту фиксированной длины. Контрольная выборка — 25% позиций (хронологический хвост или случайное разбиение, см. ключ способа).

Цель обучения — минимизация ошибки классификации при предсказании следующего символа по контексту фиксированной длины. Признак на каждой позиции — конкатенация one-hot векторов символов контекста (размерность равна длине контекста, умноженной на мощность алфавита). Доля верных ответов (accuracy) считается отдельно на обучающей и на контрольной частях; на контроль отводится 25% примеров (либо последние по порядку в тексте, либо случайная выборка — в зависимости от способа, см. ключ). Дополнительно фиксируется логарифмическая функция потерь на контроле.

Модель и программная реализация

Реализован многослойный персептрон MLPClassifier из библиотеки scikit-learn: два скрытых слоя из 96 и 48 нейронов, функция активации ReLU, адаптивный оптимизатор Adam, L2-регуляризация (alpha). При достаточном числе обучающих точек включён внутренний early stopping по доле валидации внутри train; для малых выборок итерации ограничены параметрами сходимости.

Способы подготовки выборки

Реализовано несколько способов, отличающихся длиной контекста (1, 2 или 3 символа), построением скользящего окна по всему тексту сразу или только внутри отдельных строк (без пересечения окна через перевод строки), а также типом разбиения на обучение и контроль (хронологический отрезок хвоста 25% против случайного split).

Способ	n_train	n_val	Accuracy train	Accuracy val	Итераций
w1_seq	66	23	0.1212	0.1739	39
w2_seq	66	22	0.0152	0.0000	37
w3_seq	65	22	0.4462	0.0455	61
w2_rand	66	22	0.0303	0.0000	37
w2_lines	61	21	0.2459	0.0952	54

Расшифровка ключей способов

- w1_seq: Контекст 1 символ, весь текст, хронологическое 75/25
- w2_seq: Контекст 2, весь текст, хронологическое 75/25
- w3_seq: Контекст 3, весь текст, хронологическое 75/25
- w2_rand: Контекст 2, весь текст, случайное 75/25
- w2_lines: Контекст 2, окна только внутри строки, хронологическое 75/25

На контрольной выборке наибольшую долю верных предсказаний даёт способ с ключом w1_seq. На коротком тексте значения ассигасы на контроле могут быть невысокими: число классов велико относительно объёма данных, а отложенный фрагмент может содержать редкие символы.



Рисунок 1 — Сравнение способов подготовки выборки по ассигасу на контроле (часть 1).

Часть 2. Классификация следующей строки из корпуса

Постановка

Постановка: классификация следующей строки из корпуса. Выход сети — номер строки k в списке L_0, L_1, L_2 ; результат предсказания —

полный текст строки L_k . В обучающей выборке две пары: после L_0 следует L_1 , после L_1 следует L_2 .

Корпус строк с индексами

Три строки стихотворения нумеруются L_0 , L_1 , L_2 . Именно текст одной из этих строк и является результатом предсказания: модель выбирает номер строки $k \in \{0,1,2\}$, после чего «предсказанная следующая строка» выводится как полное содержимое L_k .

Индекс k	Текст строки L_k
0	За горизонтом мечты,
1	Мы будем их трактовать в тени,
2	Где поэзия сливается в нейронный свет.

Признаки, класс и обучающая выборка

Вход сети — вектор абсолютных частот символов текущей строки по алфавиту всего трёхстрочного текста (размерность равна числу различных символов). Целевая переменная (класс) — индекс следующей строки в списке $[L_0, L_1, L_2]$, то есть для первой пары истинный класс 1 (следует L_1), для второй пары — класс 2 (следует L_2). Обучающая выборка состоит из двух объектов (две пары «текущая строка → индекс следующей»). После обучения для каждой пары сравниваются эталонный текст следующей строки и текст строки с индексом, предсказанным сетью — это и есть наглядный результат в виде целой строки.

Результаты: эталон и предсказанный текст следующей строки

Ассигасу на двух обучающих парах (проверка на тех же парах): 1.0000.

После строки №	Класс (эталон)	Класс (прогноз)	Эталон: текст следующей строки	Прогноз: текст следующей строки	Верно
1	1	1	Мы будем их трактовать в тени,	Мы будем их трактовать в тени,	да
2	2	2	Где поэзия сливается в нейронный свет.	Где поэзия сливается в нейронный свет.	да

Итоговые предсказанные строки

После L_0 : «Мы будем их трактовать в тени,».

После L1: «Где поэзия сливается в нейронный свет.».

Текущая строка (вход) для полноты картины

Для пары после строки 1 текущая строка (вход признаков): «За горизонтом мечты,».

Для пары после строки 2 текущая строка (вход признаков): «Мы будем их трактовать в тени,».

Выводы

В части 1 для микроскопического корпуса из таблицы 8.9 символьная нейросеть на отложенной выборке демонстрирует ограниченную точность; сравнение способов показывает влияние длины контекста и схемы разбиения. В части 2 подтверждено, что при выбранной постановке результат предсказания — это полный текст следующей строки из таблицы (в примере обе пары классифицированы верно).

```
~/P/NEURO_MATH/neuro_math_Yakimov_var5  P develop 13 76  python -m task_8.practice08
Практическая работа №8, вариант 5 (таблица 8.9)

Условие
В качестве текста выберем поэтические строки (таблица 8.9).
Подготовить тренировочную выборку всеми возможными способами.
Постройте модель нейронной сети, оцените ее качество.

Часть 1. Следующий символ, MLPClassifier, отложенный контроль 25%
Целевая переменная — следующий символ; признак — one-hot по контексту фиксированной длины. Контрольная выборка — 25% позиций (хронологический хвост или случайное разбиение, см. ключ способа).
способ  n_tr  n_val  acc_tr  acc_val  logloss_val
w1_seq   66    23    0.1212  0.1739    3.3517
w2_seq   66    22    0.0152  0.0000    3.4572
w3_seq   65    22    0.4462  0.0455    3.2684
w2_rand  66    22    0.0303  0.0000    3.4813
w2_lines 61    21    0.2459  0.0952    3.1742

Способы (ключ — описание):
w1_seq: Контекст 1 символ, весь текст, хронологическое 75/25
w2_seq: Контекст 2, весь текст, хронологическое 75/25
w3_seq: Контекст 3, весь текст, хронологическое 75/25
w2_rand: Контекст 2, весь текст, случайное 75/25
w2_lines: Контекст 2, окна только внутри строки, хронологическое 75/25

Наибольшая ассигнатура на контроле: способ [w1_seq]

Часть 2. Предсказание следующей строки (текст целиком)
Постановка: классификация следующей строки из корпуса. Выход сети — номер строки k в списке L0, L1, L2; результат предсказания — полный текст строки L_k. В обучающей выборке две пары: после L0 следует L1, после L1 следует L2.
Строки корпуса (индекс — текст):
L0: «За горизонтом мечты,»
L1: «Мы будем их трактовать в тени,»
L2: «Где поэзия сливается в нейронный свет.»

Результат предсказания — это полный текст строки L_k, где k — номер класса, выданный MLP (см. столбец «прогноз: текст следующей строки»).
Ассигнатура на двух парах (обучение на тех же парах): 1.0000
# класс (эталон) класс (прогноз) эталон: следующая строка | прогноз: следующая строка
1 1 1 1 «Мы будем их трактовать в тени,» | «Мы будем их трактовать в тени,» (верно: да)
2 2 2 2 «Где поэзия сливается в нейронный свет.» | «Где поэзия сливается в нейронный свет.» (верно: да)

Итоговые предсказанные строки:
после L0: «Мы будем их трактовать в тени,»
после L1: «Где поэзия сливается в нейронный свет.»

Вывод: в части 1 на коротком тексте ассигнатура на контроле ограничена; в части 2 результат предсказания — полный текст следующей строки (столбец «прогноз»); при обучении на двух парах из табл. 8.9 оба прогноза совпали с эталоном.

[файлы]
/home/garjelin/work/MAGA/NEURO_MATH/neuro_math_Yakimov_var5/outputs/practice08
* task1_bar: outputs/practice08/practice08_task1_val_accuracy_char.png
```

Рисунок 2 — Скриншот консоли.

Исходный код

Рабочий скрипт: `neuro\_math\_Yakimov\_var5/task\_8/practice08.py`.